¿Qué vende una tienda online y cuánto cancela?

Quiero comparar las ventas registradas por mes, por país y por artículo, teniendo en cuenta las cancelaciones.

Elegí el tema por mi interés en el negocio online y mi vínculo con OnCloud. Los datos son públicos y pertenecen a otra empresa.

TP2 individual. Primer trimestre de 2011. Una tienda británica.

Las preguntas del trabajo

1. ¿Cómo cambian los importes de ventas y cancelaciones entre enero y marzo?

2. ¿Qué países concentran el importe neto registrado?

3. ¿Qué artículos tienen más unidades netas registradas?

El análisis puede ayudar a decidir qué operaciones revisar con más detalle. No alcanza para recomendar stock o explicar por qué compran los clientes.

Fuente y selección

Fuente	Elección y alcance
Online Retail / UCI	Daqing Chen. Archivo Excel público con ocho columnas. Licencia CC BY 4.0.
Original conservado	541.909 renglones. Se guarda sin editar y se verifica su huella MD5.
Selección	Enero a marzo de 2011, todos los países. 99.602 renglones, 31 países.
Por qué sirve	Tiene números de factura, códigos de artículo, cantidades, precios y países para relacionar.
Fiabilidad y límite	Responsable, DOI y documentación identificables. Tienda anonimizada y datos históricos.

Fuente: archive.ics.uci.edu/dataset/352/online+retail. DOI 10.24432/C5BW33. Acceso: 2026-10-26.

Qué representa una fila

Una fila es un renglón de una factura. La cantidad puede ser negativa y el precio está en libras esterlinas (GBP).

Fila Excel / factura	Cantidad	Precio	Importe
61621 / 541431	74.215	1,04 GBP	+77.183,60 GBP
61626 / C541433	-74.215	1,04 GBP	-77.183,60 GBP

Las dos operaciones están separadas por dieciséis minutos. Conservar ambas evita confundir ventas positivas con importe neto.

C inicial indica cancelación según UCI. La fuente no permite asegurar que haya una devolución física.

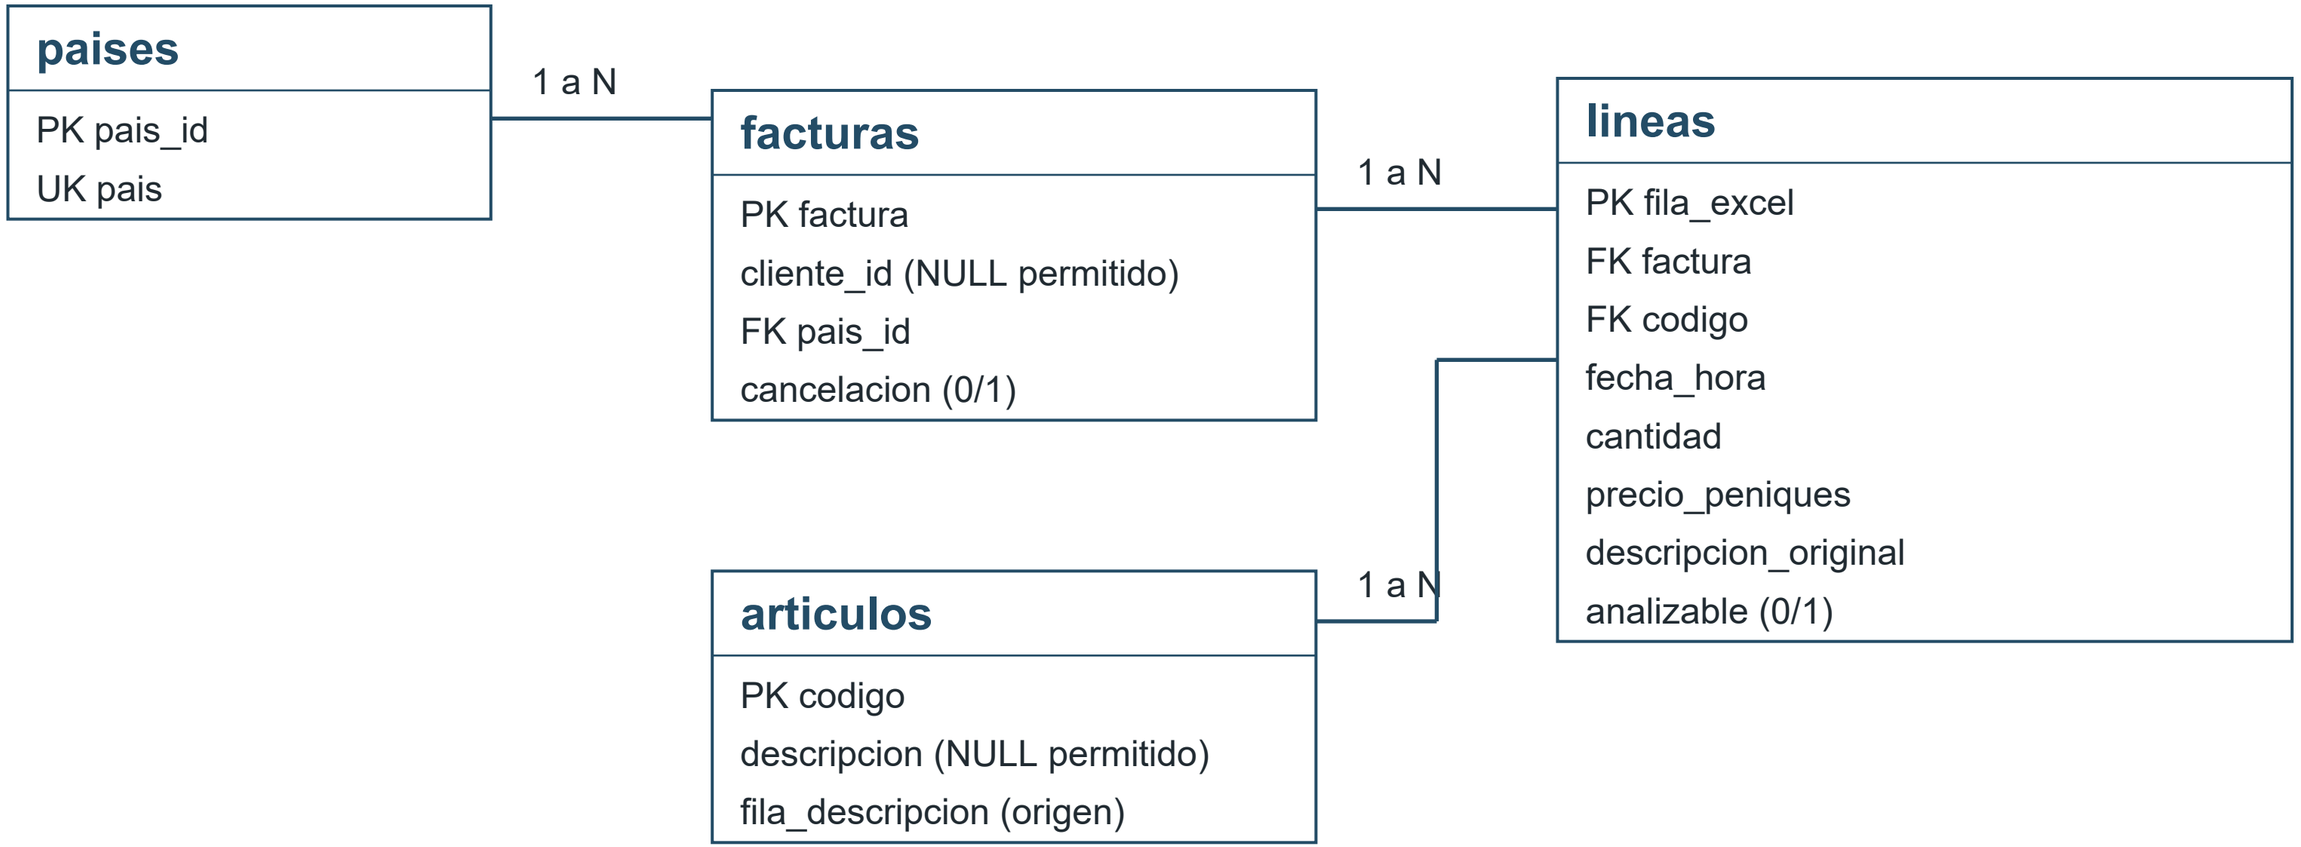
Diagnóstico antes de preparar

Lo que aparece	Cantidad	Decisión
Cliente sin identificar	29.505	Conservar el renglón y dejar el cliente como NULL.
Descripción ausente	344	No inventar el nombre del artículo.
Precio cero	513	Guardar en la base y separar del análisis de ventas.
Renglones idénticos a otros	784	Conservar y medir el efecto de quitarlos.
Descripciones con espacios en bordes	18.557	Normalizar la etiqueta y guardar el texto original.
Facturas con horas distintas	22	Guardar la hora en cada línea.

El 29,62 % de los renglones no tiene cliente identificado. Eso limita el estudio de clientes, pero no impide sumar importes.

Cuatro tablas que se relacionan

Los cuatro dataframes salen del Excel. El código define las reglas y las claves de país.



PK: clave primaria. FK: clave foránea. UK: valor único. Cada línea conserva la fila del Excel como vínculo con el original.

Preparación y comparación

Regla	Resultado
Fecha y hora por línea	99.602 fechas guardadas en texto ISO, sin convertirlas a la hora argentina.
Precio en peniques	99.602 precios multiplicados por 100. Sin pérdida de decimales en esta selección.
Etiqueta de artículo	18.571 textos normalizados. Se conserva la descripción recibida y la fila de la etiqueta elegida.
Precio cero	513 renglones separados de los resultados, todos conservados en SQLite.
Antes / después	99.602 renglones en ambos casos. 99.089 renglones entran en los tres resultados.

La bitácora registra condición, motivo, acción y afectados. La carga se confirma junta mediante una transacción.

Consultas a la base

Las ocho consultas están guardadas en SQL. Las tres principales agrupan por mes, país y artículo. Los gráficos parten de esos resultados.

```
SELECT p.pais,
       SUM(l.cantidad*l.precio_peniques)/100.0 AS neto_gbp
FROM lineas l JOIN facturas f ON l.factura=f.factura
JOIN paises p ON f.pais_id=p.pais_id
WHERE l.analizable=1
GROUP BY p.pais
ORDER BY neto_gbp DESC;
```

Cada fila devuelve un país. El JOIN enlaza por claves. Otro control utiliza las cuatro tablas y verifica que no se multipliquen líneas ni dinero.

Comprobaciones del proceso

Prueba	Evidencia esperada y obtenida
Caso conocido	74.215 × 104 = 7.718.360 peniques. La compra y su cancelación suman cero.
Casos separados	Fecha imposible, NA, espacios, precio con tres decimales y cero.
Claves y relaciones	Sin claves repetidas ni referencias obligatorias huérfanas. JOIN sin multiplicar importes.
Rollback	Una inserción válida se revierte al fallar la siguiente por una factura inexistente.
Reconstrucción	Una base nueva devuelve exactamente los mismos resultados en las ocho consultas.

También se concilian las filas seleccionadas y separadas, se compara SQL contra R y se verifica que el original conserve su MD5.

Límites de lo que puedo afirmar

Los resultados describen una sola tienda británica en tres meses de 2011. Incluye compradores mayoristas.

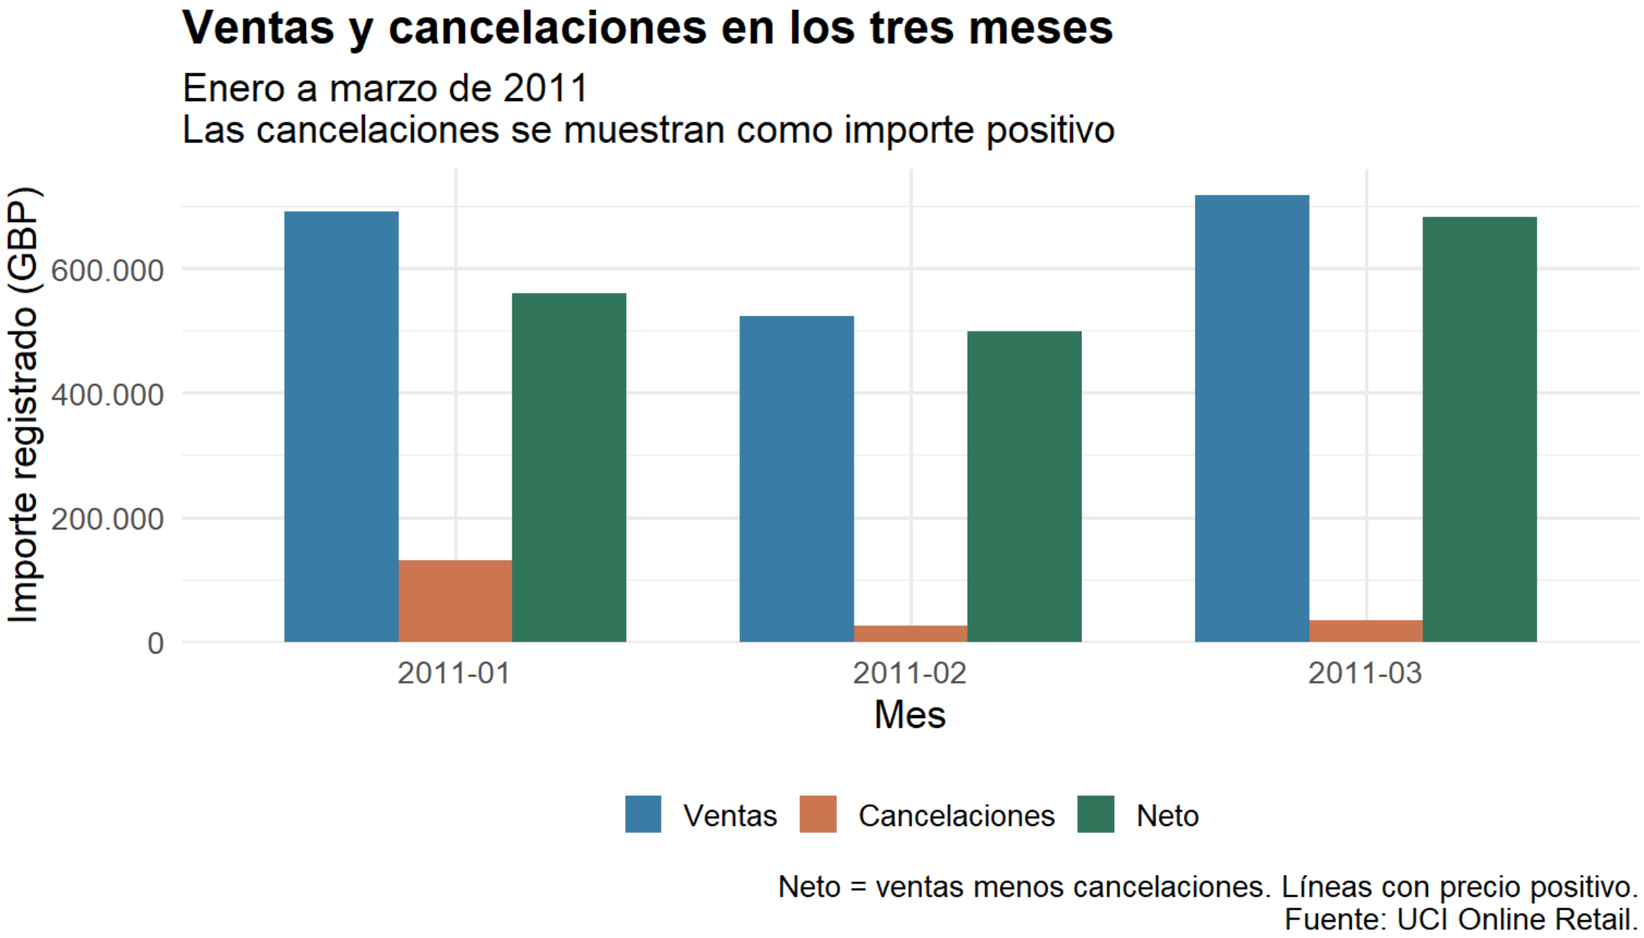
El neto es cantidad por precio registrado. No conozco costos ni información contable suficiente para hablar de ganancia.

Una cancelación del trimestre puede corresponder a una compra anterior. No calculo una tasa de devolución por compra.

Conservo las 784 repeticiones porque no puedo demostrar que sean errores. Si quitara las copias posteriores, el neto bajaría 3.841,04 GBP.

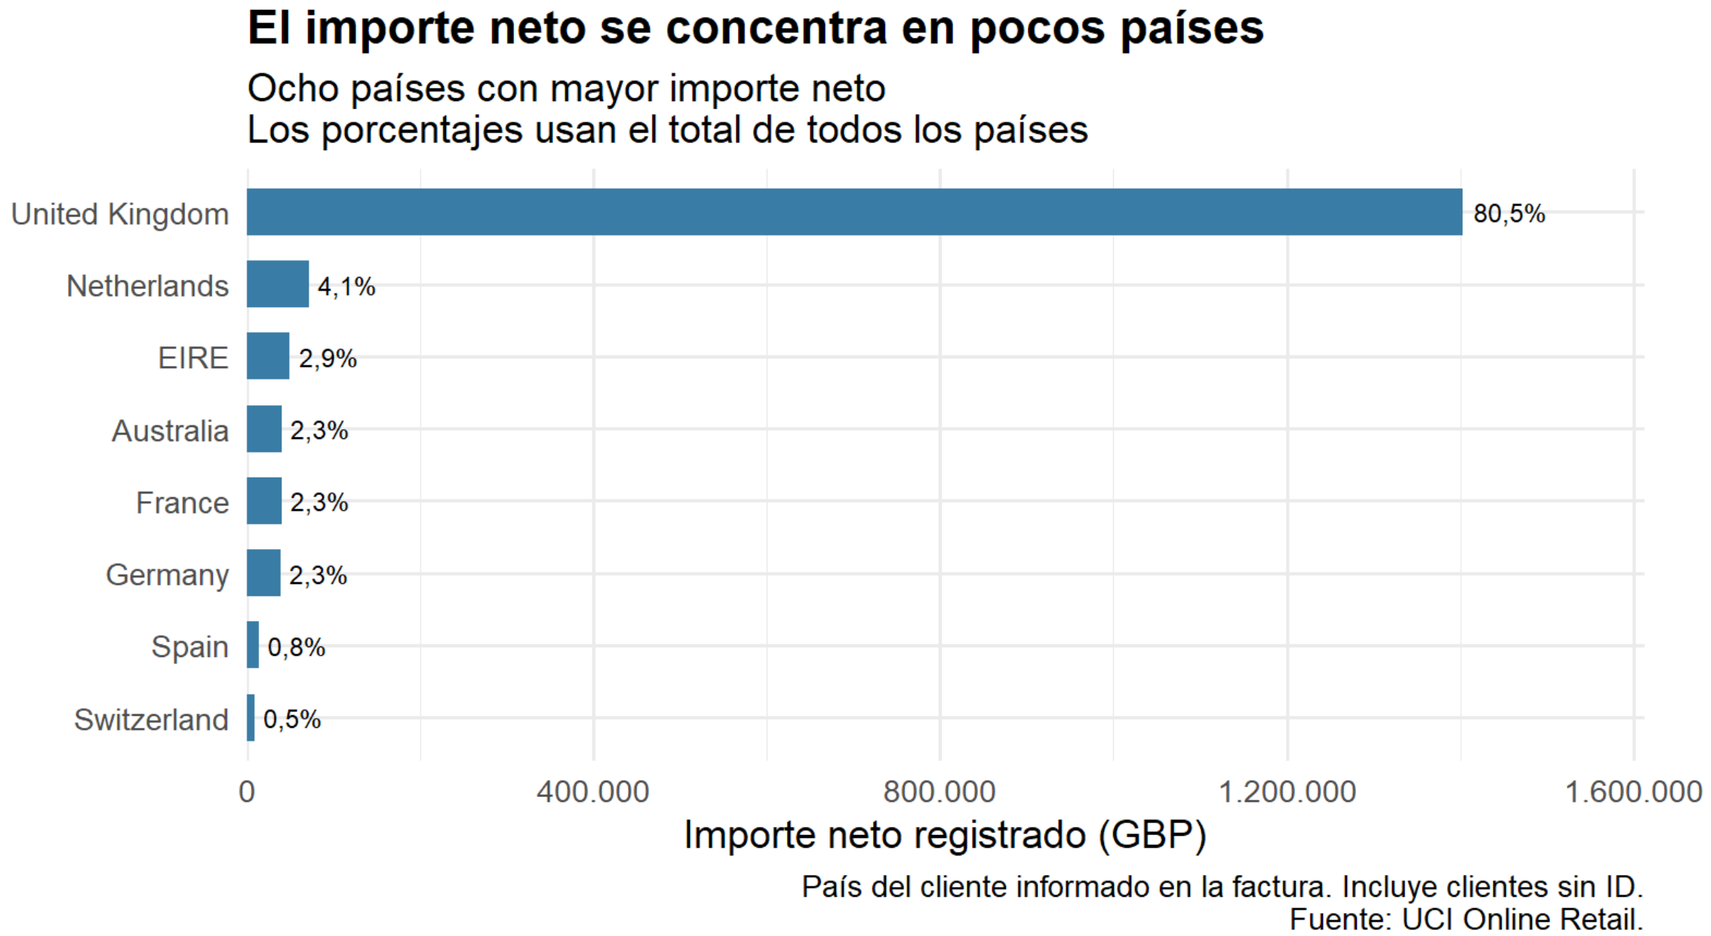
Fuente: Chen (2015), Online Retail, UCI, CC BY 4.0. Código y documentación en el repositorio del TP2.

Marzo tiene el mayor neto del trimestre



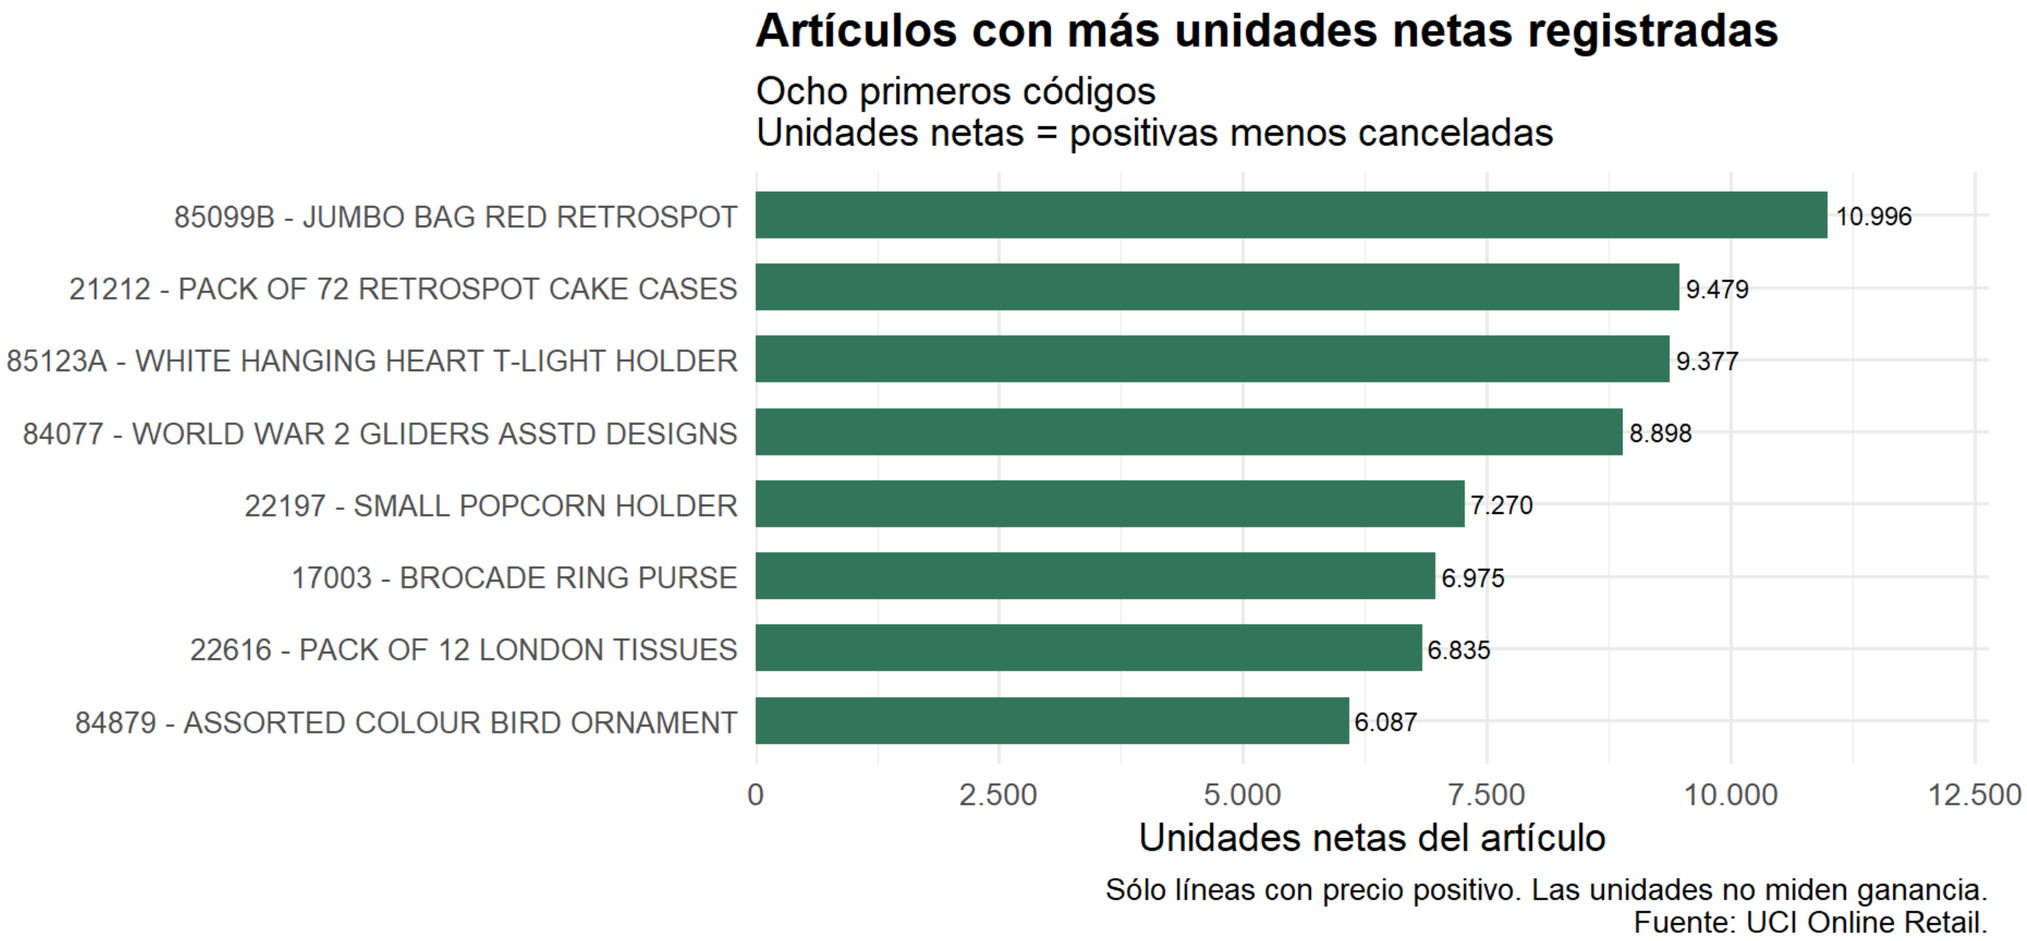
Marzo: 683.267,08 GBP netos. Enero concentra más cancelaciones. Tres meses no permiten afirmar una tendencia anual.

Reino Unido concentra el 80,5 % del neto



United Kingdom: 1.402.263,60 GBP. El porcentaje usa el neto de los 31 países. Describe esta tienda, no el tamaño de cada mercado.

El código 85099B encabeza las unidades netas



10.996 unidades netas de JUMBO BAG RED RETROSPOT. Las cantidades son unidades comerciales del código y no miden rentabilidad.